

Selbsteinschätzung im Projekt

Yevgeniy Gubov

Aufgabe 1.1: Selbsteinschätzung im Projekt

a) Rolle in der Gruppe

Im Rahmen unseres Gruppenprojekts zur Vorhersage kardiovaskulärer Erkrankungen haben Christian Volkert und ich gemeinsam an der Implementierung und Analyse der Maschine-Learning-Modelle gearbeitet. Wir haben beide unabhängig voneinander den Python-Code für die Datenbereinigung, das Feature Engineering und die Modellentwicklung geschrieben und anschließend unsere Ergebnisse verglichen. Aufgrund meiner beruflichen Tätigkeit konnte ich nicht regelmäßig an den Vorlesungen teilnehmen. Christian hat mich hierbei unterstützt, indem er mir die relevanten Vorlesungsinhalte und Informationen von Prof. Guterding weitergegeben hat. Dadurch konnten wir das theoretische Wissen aus der Vorlesung effektiv mit der praktischen Umsetzung verbinden.

b) Themen aus der Vorlesung

Unser Projekt steht in direktem Zusammenhang mit mehreren Vorlesungsthemen. Im Bereich der überwachten Klassifikation haben wir drei Verfahren angewendet: Die Logistische Regression als lineares Modell, Random Forest als Ensemble-Methode mit Bagging und XGBoost als Gradient-Boosting-Verfahren. Das Thema Feature Engineering wurde praktisch umgesetzt, indem wir aus den Rohdaten neue Merkmale wie BMI, Blutdruck-Kategorien und einen Risiko-Score abgeleitet haben. Die Kreuzvalidierung zur Modellbewertung und verschiedene Evaluationsmetriken wie ROC-AUC, Precision und Recall wurden zur Beurteilung der Modellgüte eingesetzt. Auch das Thema Overfitting-Vermeidung durch Hyperparameter-Tuning fand Anwendung.

c) Wichtigste Ergebnisse

Die wichtigsten Ergebnisse unseres Projekts lassen sich wie folgt zusammenfassen: XGBoost erzielte mit einer ROC-AUC von 79,8% und einer Accuracy von 73,2% die beste Performance, gefolgt von Random Forest und Logistischer Regression. Die Unterschiede zwischen den Modellen waren jedoch gering, was auf weitgehend lineare Zusammenhänge im Datensatz hindeutet. Als wichtigste Prädiktoren für kardiovaskuläre Erkrankungen wurden konsistent der systolische Blutdruck, das Alter und der Cholesterinspiegel identifiziert. Überraschend war, dass Lebensstilfaktoren wie Rauchen und Alkoholkonsum keinen starken direkten Einfluss zeigten – sie wirken vermutlich indirekt über die physiologischen Parameter. Eine zentrale Erkenntnis war auch, dass selbst einfache Modelle wie die Logistische Regression brauchbare Ergebnisse liefern können, wenn die Daten gut aufbereitet sind.

Aufgabe 1.2: Einschätzung der anderen Gruppenmitglieder

Peer-Evaluation für das Gruppenprojekt:

Nachname	Vorname	x	Gleiche Note	Bessere Note	Schlechtere Note	Punkte
Gubov	Yevgeniy	X	X			50
Volkert	Christian		X			50

e) Begründung

Die Arbeit im Team war ausgewogen und kooperativ. Christian Volkert und ich haben gleichwertig zum Projekterfolg beigetragen, wobei wir unterschiedliche Stärken eingebracht haben.

Aufgrund meiner beruflichen Tätigkeit konnte ich nicht regelmäßig an den Vorlesungen teilnehmen. Christian hat mich hierbei sehr unterstützt, indem er mir alle relevanten Informationen und Inhalte aus den Vorlesungen von Prof. Guterding weitergegeben hat. Dadurch konnte ich trotz meiner Abwesenheit stets auf dem aktuellen Stand bleiben und das theoretische Wissen in die praktische Umsetzung einfließen lassen.

Bei der technischen Umsetzung haben wir beide unabhängig voneinander an der Python-Programmierung, der Datenanalyse und der Modellentwicklung gearbeitet. Anschließend haben wir unsere Ergebnisse verglichen und die besten Ansätze für das finale Projekt zusammengeführt. Diese Vorgehensweise hat uns ermöglicht, Fehler frühzeitig zu erkennen und die Qualität unserer Analyse zu verbessern.

Insgesamt war die Zusammenarbeit effektiv und die Aufgabenverteilung fair, weshalb ich eine gleiche Bewertung für beide Teammitglieder als angemessen erachte.